基本信息

姓 名:杨新权 出生年月:1988.05

电 话:18811171651 学 历:硕士

邮 箱: starspringcloud@gmail.com 住 址:北京市

教育经历

电子科技大学 2010/08-2013/06 硕士/模式识别

福建师范大学(一本) 2006/09-2010/07 本科/电子信息工程

工作经历

2015.03-至今 阿里集团-高德-搜索 推荐算法专家

1. 泛搜:高德本地生活(酒店、美食、生活服务、景点等)搜索,用户并没有明确的 poi(Point of Interest)倾向,需要的是某一类的 item 的集合。 流量入口为高德地图框搜、高德附近页金刚位(频道位),主图工具箱 icon、poi 周边搜、酒店 portal 页等。建模任务主要为 ctr/cvr。建模侧重用户个性化和 LBS 空间相关性。工作内容涉及召回、粗排、精排、重排。

2. 精搜:高德地图基础搜索,用户有明确的 poi 意图。流量入口主要是高德的框搜。建模侧重相关性(文本相关性+空间相关性)。建模任务主要为 ctr。负责过 query 的成分分析(NER); query 品牌识别(NLU); 深度语义相关性; 搜索词自动补全(suggest)。

2013.07- 2015.3 奇虎 360 NLP 算法工程师

1. 传统 NLP 任务: 利用基于 n-gram 的分词算法对短信内容进行分词; Viterbi 算法的同义词变换; 基于模版的对话系统。

项目经验

2018.05-至今 高德 本地生活

高德本地生活(酒店、美食、生活服务、景点等)搜索建模:

- 1. 召回:多路召回架构,包括文本召回(term 倒排索引)、个性化深度向量召回、user trigger 召回、冷启动保量召回。向量召回模型使用类似 MIND 模型的双塔序列结构。使用 softmax loss,增加自监督学习作为辅助 loss。最后多路结果按比例 merge (100:100:60:40)。
- 2. 粗排:向量召回使用双塔 cosine similarity 排序,文本召回路使用 gbrank 模型,建模任务为 ctcvr 任务。特征分 4 个维度:user 侧(profile + 行为序列); item 侧(商品属性); query 信息; LBS 空间特征。
- 3. **精排**:样本选取有用户行为的展现日志落地表,正负样本比例约为 1:4,特征体系和粗排类似。学习方法为 point + pair-wise的方式。模型从 wide&deep 到使用 deepfm 来学习特征的自动交互、再到使用 multi-head attention 对用户长期行为序列、实时行为序列学习 LastN 信息,并使用 sim 模型的 hard-search 思路筛选 attention 候选集。学习任务为 ctr/cvr 多任务(essm)。
- 4. **重排**:精排只注重 item 的排序指标,缺乏整个 list 的视野,做不到整体最优化。重排两个建模目的:a. 推荐系统锚定效应;b. 搜索结果的多样性。样本构造方法:对线上精排分进行落表,选取精排分 top100。建模任务为 ctcvr。特征体系复用精排并增加上下文 context 特征。 模型结构为 PRM:把精排的输出作为 transformer encoder 模块的输入,softmax CE 作为 loss,同时增加辅助 loss(多样性)

- 5 统一模型:多行业多任务建模:高德本地生活有多个业务(酒店、美食、生活服务、景点等),分别维护一套模型成本巨大,且部分场景数据稀少,不利于建模。此外同一个业务也有这多种任务(ctr、cvr)。在综合 PLE、ESMM、HiNet 等模型优点的基础上,实现了多行业多任务的统一精排模型。上线取得良好的正向收益
- 6 多样性策略 (DPP), 用户冷启动 (Airbnb KDD 2018) 利用用户历史行为训练 user embedding, 基于探索策略的商品冷启动。

项目经验

2017.03-2018.03 高德

搜索词补全

高德搜索建议 (suggest): 用户在输入框输入 query 的过程中,自动补全 query。并推荐用户可能感兴趣的 poi/keyword。

- 1. 前缀树召回候选结果,利用文本相关性(cgr、cpr 等)进行粗排,获得候选 poi/keyword。
- 2. 样本对齐:把中间输入过程的所有 query,对齐到最终发起搜索的完整 query 上。
- 3. 基于用户历史行为、poi 热度特征(点击率)、query 特征,空间特征,构造 2-3 阶交叉特征。
- 4. pair-wise loss + gbrank 建模,通过调 loss function 方法对模型引入先验知识

2015.03-2017.03

高德

基础搜索

高德基础搜索,用户希望检索某一指定的 POI,需要关注文本和空间相关性。系统架构分为:NLP 模块、倒排索引召回,相关性排序(粗排)、ctr 预估排序(精排)。

1. 基于 bert 的深度相关性模型:

通过用户历史点击行为,挖掘 query 和 doc title 对,有点击为正样本,负样本进行随机采样,正负样本为1:4。模型为双塔结构, 基塔是 bert 中文预训练版。利用高德的数据进行 fine-tuning, freeze 底层 embedding,在 CLS 输出增加 FC 层。使用 softmax ce 作为分类 loss。

- 2. 品牌搜:
 - a) 品牌识别: 多分类建模,基于 fasttext 的 query 意图识别,样本增广:基于种子样本(人工标注 + 品牌知识库),利用种子样本 + 同义词 + 扩展词生成一个品牌识别模板,利用模版扫描 query log 来构造新的样本, loss 为 hierarchical softmax。
 - b) 品牌排序:分层排序,优先考虑权威性,其次考虑距离。
- 3. 成分分析(chunk):

NER 任务。针对地图场景,提炼20种成分标签,进行人工标注,作为CRF的训练样本,模型准召可达90%。 亮点:采用2个CRF模型串行(分别预测边界、标签)、标签归并等手段,提升4倍预测速度

专业技能

- 1. 熟悉垂类搜索/推荐系统:粗排、精排、重排序; 多行业多任务建模、多样性、冷启动
- 2. 搜索相关经验: learning to rank, Text Classification, Semantic matching, NER
- 3. 熟悉 tensorflow 框架和大数据开发。有良好编程功底 Python、c++ 、c、java、hive